3 - Indexación. Ficheros con organización secuencial indexada.

3.1 - Organizaciones para acceso directo: ficheros relativos.

3.2 - Concepto de índice. Técnicas de indexación de ficheros. Organización indexada.

3.3 - Organizaciones con varios índices secundarios: ficheros invertidos.

3.4 - Estructuras de árbol y su utilización en las organizaciones indexadas: árboles B y B*.

3.5 - Familia de árboles B+ y organización secuencial indexada.

3.1 - Organizaciones para acceso directo: ficheros relativos.

Objetivo: reducir (minimizar) el coste de las operaciones de *búsqueda*, implementando un acceso "*directo*" a los datos

→ tiene sentido en soportes "direccionables"

Solución: *establecer una conexión entre el* valor del dato *y su* ubicación física

clave: pequeña porción de información que **identifica** (nivel lógico) un dato

- Propia
- Añadida

es única para cada dato

¿ y si hay valores repetidos ?

fichero relativo ≡ fichero en el que existe una relación "predecible" entre la clave de un dato y su ubicación física.

R(*clave*) → *ubicación física*, siendo R una función de cálculo de direcciones

→ **Organización ligada a la clave**

ficheros relativos: tipos y operadores básicos

la implementación de la función R → diferentes tipos de ficheros relativos :

- "mapeo" directo → *ficheros directos*
- búsqueda en directorio → *ficheros indexados*
- cálculo de direcciones → *ficheros dispersos*

operadores básicos:

- *Asociar (f, nombre)*
- *Disociar (f)*

- *LeerDato (f, clave, d, exito)*
- *EscribirDato (f, clave, d, exito)*

- *EliminarDato (f, clave, exito)*

• • •

¿ y para obtener todos los datos ? → Op. secuenciales *PrimerDato(f,d,exito) + SiguienteDato (f,d,exito)*

ficheros relativos: *ficheros directos con mapeo absoluto*

***ficheros directos*:**

- "mapeo" directo absoluto: ⇒ clave ≡ dirección física

ventajas:
- *simplicidad* (∄ cálculo direcciones) y *eficiencia*

inconvenientes:
- *dependencia* de la representación física → registros "pinchados" (pinned)
  → **dificultad de reestructuración y gestión del espacio de almacenamiento**
- la clave no es adecuada (no tiene relación con la información del dato)

Pb. semántico: ¿cómo se implementa la existencia de un dato ?
→ responsabilidad del usuario ?

→ no se suele usar

ficheros relativos: *ficheros directos con mapeo relativo*

***ficheros directos*:**

- "mapeo" directo relativo: ⇒ clave ≡ dirección relativa (NRR)

ventajas:
- *bastante simple* y *eficiente*

inconvenientes:
- la clave puede no tener relación con la información del dato (suele ser algo añadido)
- implementación un poco más compleja

la no existencia de un dato →
- marca de borrado (costoso)
- dirección no existente

} en la op. de creación, o responsab. del usuario

implementación:
- contigua → eficiente, pero muy poco adecuada (en general)
- "tabla" de traducción
  - *directa* (pb. tamaño y gestión)
  - *lista encadenada* (versátil, pero menos eficiente)
  - *multinivel* (compromiso adecuado eficiencia-eficacia)

ficheros directos: ejemplos de implementación

☛ casi todos los gestores incluyen ficheros directos con operadores de "bajo nivel" (∄ relación con la información de los datos) e incluyen los operadores de tratamiento secuencial

en **C**

int **fseek** (FILE **fichero*, long *direcciónRelativa*, int *origen*)
siendo origen = SEEK_SET *(=principio)*, SEEK_CUR *(=actual)*, o SEEK_END *(=final)*

long **ftell** (FILE **fichero*) *(devuelve la posición actual, o -1L si hay error)*

int **fsetpos** (FILE **fichero*, const fpos_t * *ptrDir*)
Sitúa el "fichero" en la posición almacenada en *ptrtDir por la función fgetpos. Devuelve 0 si no error.

int **fgetpos** (FILE **fichero*, fpos_t * *ptrDir*)
copia en *ptrtDir la posición actual sobre el "fichero", para uso posterior con fsetpos. Devuelve 0 si no error.

void **rewind** (FILE **fichero*) *{ rewind(f) = fseek(f,0L,SEEK_SET}*

3.2 - Concepto de índice. Técnicas de indexación de ficheros. Organización indexada

Objetivo: utilizar como *clave* una *abstracción* de la información *del dato*

⇩

búsqueda en directorio ≡ representar explícitamente la relación entre *valores de la clave* y la *ubicación física del dato*

INDICE ≈ **VECTOR** (tabla) de registros
- absoluta
- relativa (NRR)

fichero indexado ≡ fichero cuya *organización* está basada en un índice (o más)

☛ acceso al dato ⇒ *2 pasos* : **búsqueda en índice + acceso al dato**

☛ suelen implementarse en base a dos ficheros: **f. índice + f. datos**

→ **pueden estar integrados en un único fichero** (reg. diferentes)

Concepto de índice: ejemplo

☛ *Información de personas. Como clave se usará el DNI* (identifica una persona)

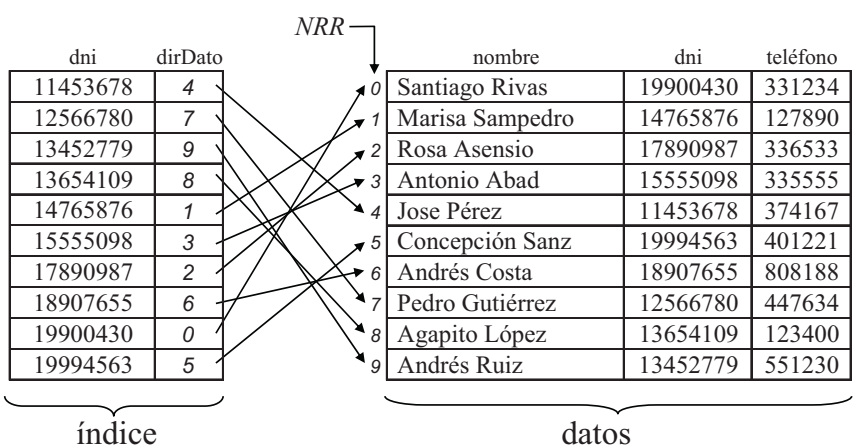

Concepto de índice: *ventajas/inconvenientes*. Operadores básicos.

ventajas:

- menor tamaño del índice ⇒ *mayor eficiencia búsqueda* (↑ factor de bloque) → **podría caber en memoria**
- registros del índice de long. fija (normalmente) ⇒ *acceso + simple y eficiente* → **(p.e. búsqueda binaria)**
- simplifica la utilización de registros de longitud variable (representados como tales)
- permite acceso directo (eficiente) a los datos utilizando cualquier campo clave, incluso simultáneamente (varios índices)
- permite mantener una (o varias) *ordenación* lógica de los datos *sin moverlos* → *el mantenimiento del orden es muy eficiente*

inconveniente:

- operaciones de *procesamiento secuencial* (afectan a muchos datos) son *más lentas*

operadores básicos:

- *Asociar (f, nombre)*
- *Disociar (f)*

- *LeerDato (f, clave, d, exito)*
- *EscribirDato (f, clave, d, exito)*
- *EliminarDato (f, clave, exito)*

- *PrimeraClave (f, clave, exito)*
- *SiguienteClave (f, clave, exito)* → o dato *(pero a través de la clave)*

Concepto de índice: *índice denso y no-denso*

una entrada de índice por cada dato ≡ ***índice denso***

→ el índice puede ser excesivamente grande

Solución: elegir un *subconjunto de claves* ⇒ ordenación (parcial) de los datos por la clave

índice no-denso

dni	dirDato
11453678	0
13654109	3
19900430	8

Se puede aprovechar la organización física en bloques

NRR	nombre	dni	teléfono
0	Jose Pérez	11453678	374167
1	Pedro Gutiérrez	12566780	447634
2	Andrés Ruiz	13452779	551230
3	Agapito López	13654109	123400
4	Marisa Sampedro	14765876	127890
5	Antonio Abad	15555098	335555
6	Rosa Asensio	17890987	336533
7	Andrés Costa	18907655	808188
8	Santiago Rivas	19900430	331234
9	Concepción Sanz	19994563	401221

Ordenados por DNI

Concepto de índice: *densidad de un índice. Ejemplos*

densidad *del índice* = nº entradas / nº total de datos

el tratamiento de los datos se hace en bloques ⇒ en el índice la ref. del bloque

→ Bloque "***ancla***" ≡ primer bloque de la subsecuencia

FICHERO

INDICE		ordenado	no ordenado
denso	ordenado	posible	IS3
	no ordenado		fichero
no denso	ordenado	VSAM ISAM UFAS	
	no ordenado	posible	

IS3 ≡ índice secuencial tipo AS400
ISAM ≡ secuencial indexado IBM
VSAM ≡ secuencial indexado regular IBM
UFAS ≡ secuencial indexado BULL

Implementación de una Organización Indexada simple

implementación: operaciones de mantenimiento ⇒ **compromiso**

- funcionalidad
- eficiencia
- seguridad

⇩ acceso al índice y a los datos

→ más complejas y menos eficientes (a veces) con índices no-densos

☞ ***el coste de la búsqueda (aun binaria) no tiene por qué ser despreciable***

Ejemplo: aplicación al diseño de una organización indexada sencilla

• • • •

Concepto de índice: *tipos de índices*

la extensión de la idea de indexación → diferentes tipos de índices

- índice ***primario*** ≡ se utiliza la *clave (primaria)* del dato ⇨
- índice ***de agrupamiento*** ≡ se utiliza un *campo de ordenación* del dato ⇨
- índice ***secundario*** ≡ se utiliza la *cualquier otro campo* (clave o no) ⇨

Si todavía es muy grande el índice → nuevo índice sobre el índice ⇨

índice ***multinivel***

aumenta la eficiencia de la búsqueda, pero complica la gestión

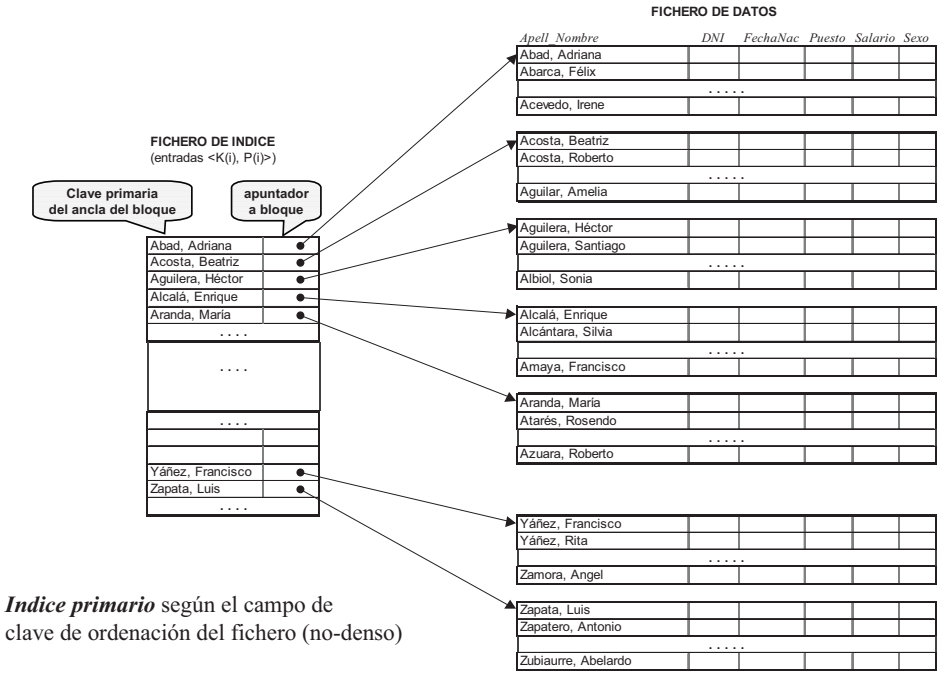

Indice primario según el campo de clave de ordenación del fichero (no-denso)

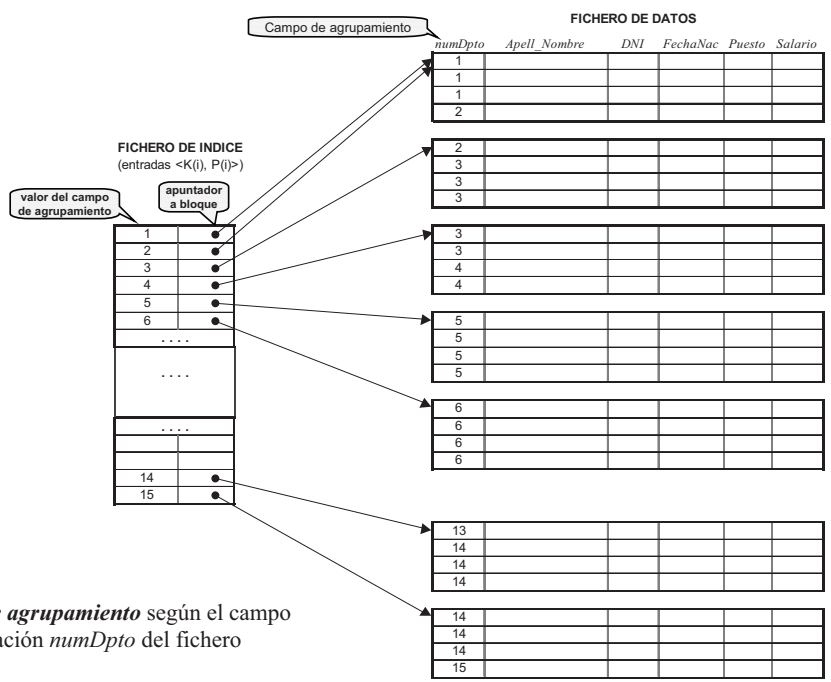

Indice de agrupamiento según el campo de ordenación *numDpto* del fichero

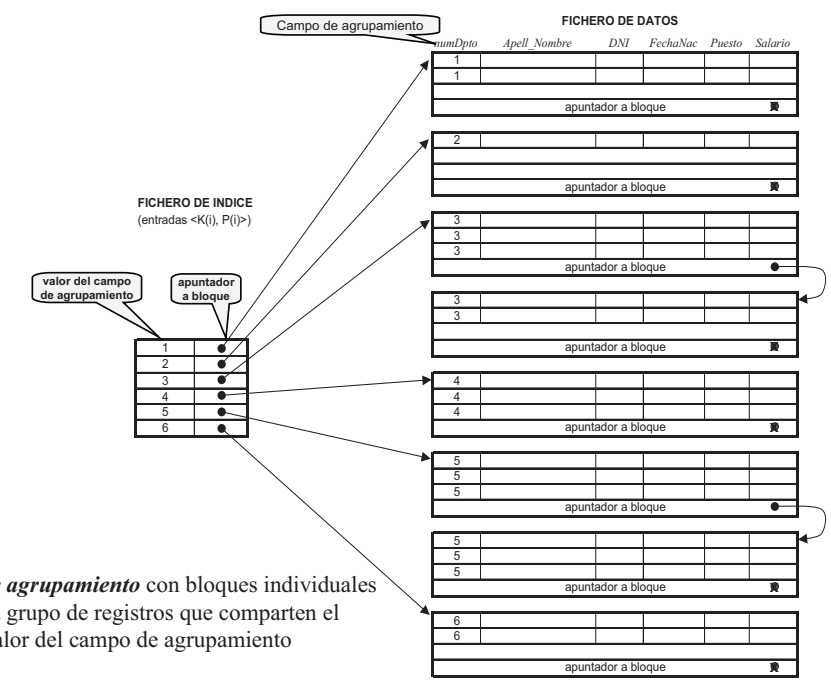

Indice de agrupamiento con bloques individuales para cada grupo de registros que comparten el mismo valor del campo de agrupamiento

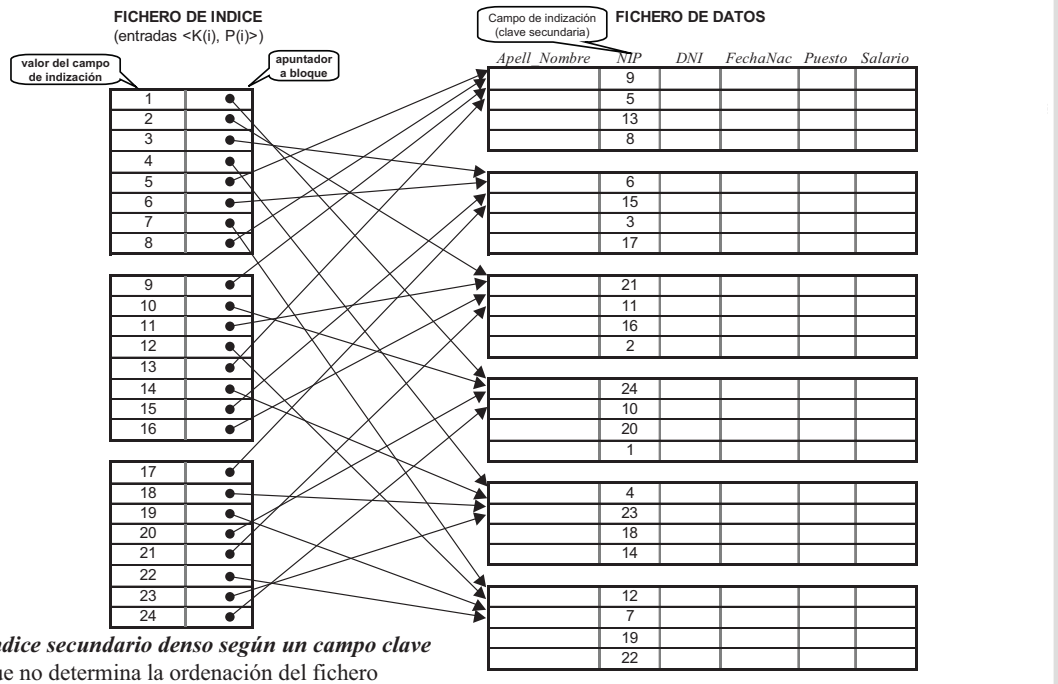

Indice secundario denso según un campo clave que no determina la ordenación del fichero

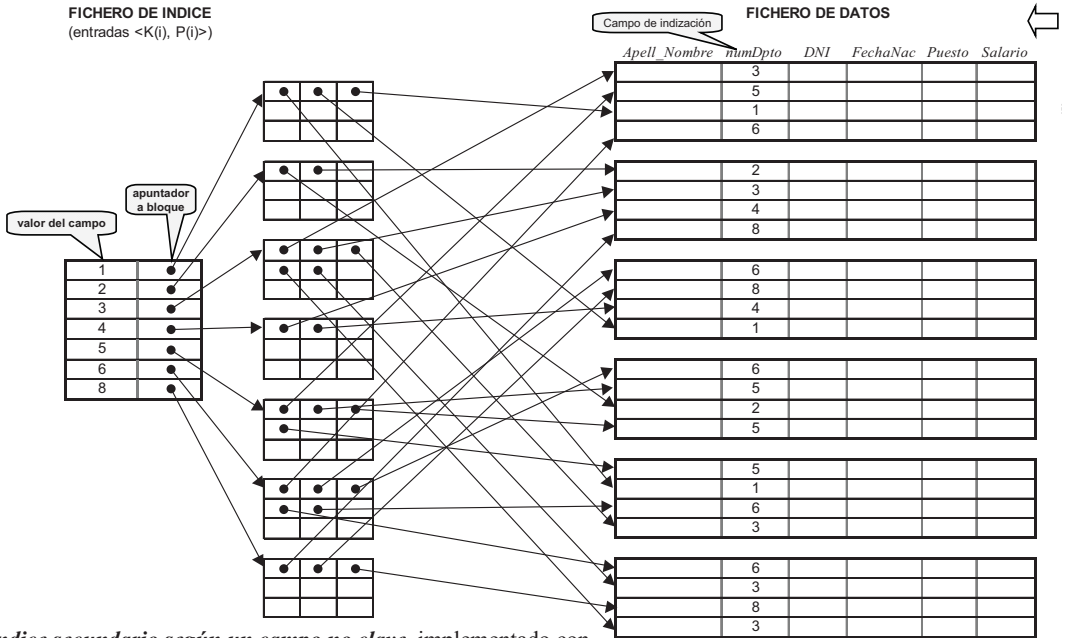

Indice secundario según un campo no clave, implementado con un nivel de indirección (entradas del índice de longitud fija y valores únicos)

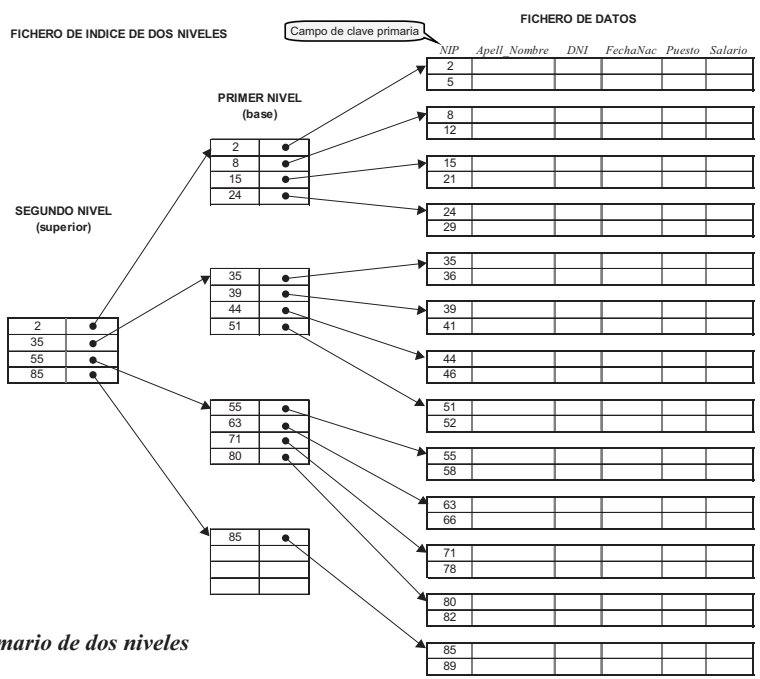

Indice primario de dos niveles

3.3 - Organizaciones con varios índices secundarios: Ficheros invertidos.

Objetivo: acceso eficiente ("*directo*") a los datos utilizando diversos criterios

no tienen por qué ser información clave

ejemplo: información de grabaciones musicales

Índice primario

ANG3795	167
COL31809	353
COL38358	211
DG139201	396
DG18807	256
FF245	442
LON2312	32
MER76016	300
RCA2626	77
WAR23699	132

grabaciones (fichero directo)

32	LON	2312	Romeo y Julieta	Prokofiev ...
77	RCA	2626	Cuarteto en do sostenido menor	...
132	WAR	23699	Touchstone	Corea ...
167	ANG	3795	Sinfonía nº 9	Beethoven ...
211	COL	38358	Nebrasca	Springsteen ...
256	DG	18807	Sinfonía nº 9	Beethoven ...
300	MER	76016	Suite El gallo de oro	Rimsky ...
353	COL	31809	Sinfonía nº 9	Dvorak ...
396	DG	139201	Concierto para violín	Beethoven ...
442	FF	245	Good News	Sweet Honey In The ...

Organizaciones con varios índices secundarios

Solución: utilizar *varios índices* sobre los datos

→ ***Densos***, pues sólo puede haber una ordenación física

ejemplo: acceso a la información musical por compositor

Índice secundario

BEETHOVEN	167
BEETHOVEN	396
BEETHOVEN	256
BEETHOVEN	77
COREA	132
DVORAK	353
PROKOFIEV	32
RIMSKY_KORSAKOV	300
SPRINGSTEEN	211
SWEET HONEY IN THE R	442

NRR

⇨ o también

Índice secundario

BEETHOVEN	ANG3795
BEETHOVEN	DG139201
BEETHOVEN	DG18807
BEETHOVEN	RCA2626
COREA	WAR23699
DVORAK	COL31809
PROKOFIEV	LON2312
RIMSKY_KORSAKOV	MER75016
SPRINGSTEEN	COL38358
SWEET HONEY IN THE R	FF245

clave primaria

Organizaciones con varios índices secundarios: *Ficheros invertidos*.

Problemas:
- los índices secundarios tienen *valores repetidos* (salvo que sean clave)
- la actualización/inserción/eliminación ⇒ *reactualizar todos los índices*
  - ref. absoluta
  - NRR

☛ acceso a través de índice secundario ⇒ *inversión del proceso de obtención de información*

fichero invertido ≡ fichero organizado a partir de índices secundarios basados en la clave primaria

el fichero está invertido con respecto a la clave, para cada uno de los índices secundarios

tipos
- *totalmente invertido* (se utilizan todos los campos)
- *parcialmente invertido* (sólo se utilizan algunos campos)

Ficheros invertidos: ventajas

☛ la información del índice no tiene por qué estar en el dato *(es redundante)*

un *fichero totalmente invertido* puede implementarse *sólo con índices secundarios*

(no es interesante por razones de eficiencia y seguridad)

ventajas:
- acceso eficiente para diferentes criterios (campos)
- se pueden responder a preguntas complejas sin acceder a los datos *(operaciones con listas)*

Ficheros invertidos: *implementación (I)*

implementación:

- índice con valores no repetidos del campo ⇒ listas de claves primarias

Índice secundario

BEETHOVEN	ANG3795 DG139201 DG18807 RCA2626
COREA	WAR23699
DVORAK	COL31809
PROKOFIEV	LON2312
RIMSKY_KORSAKOV	MER75016
SPRINGSTEEN	COL38358
SWEET HONEY IN THE R	FF245

- solución más interesante: separar las listas del índice

Ficheros invertidos: *implementación (2)*

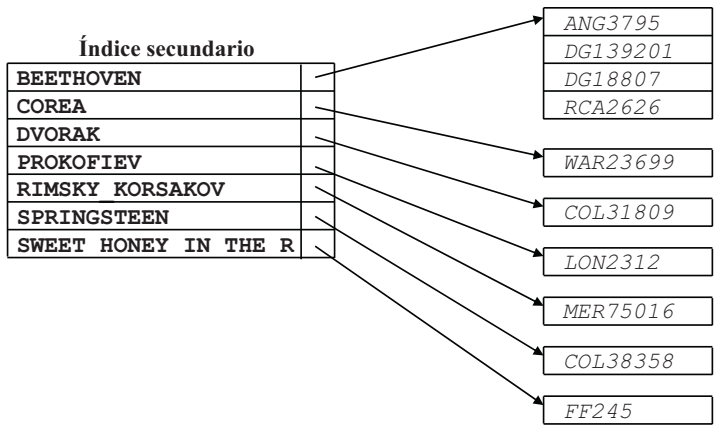

Ficheros invertidos: *implementación con listas invertidas*

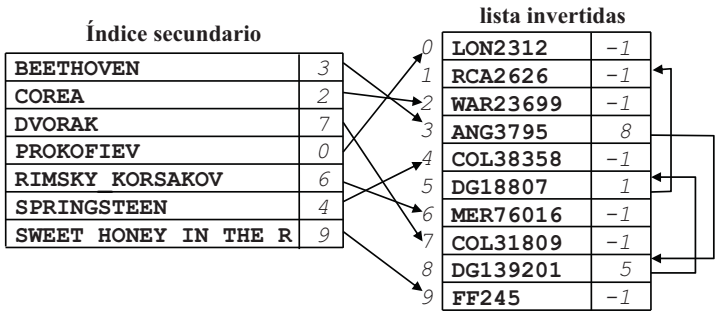

ventajas de las *listas invertidas*:
- gestión más eficiente (op. mantenimiento)
- menor ocupación memoria

Ficheros invertidos: *referencia de los datos*

Utilización de la clave primaria como referencia:

ventajas:
- mayor fiabilidad *(es una redundancia)*
- no es necesario reorganizar el índice secundario en la eliminación
- mayor independencia de la ubicación de los datos

inconveniente:
- mayor coste de la búsqueda (hay que buscar en el índice primario)

3.4 - Estructuras de árbol y su utilización en las organizaciones indexadas: árboles B y B*.

Idea de *búsqueda binaria* en el índice → *organización indexada como* ***árbol binario de búsqueda***

respecto al índice como vector

ventajas:
- mayor eficiencia búsqueda (≅)
- mayor eficiencia en operaciones de mantenimiento

Pb:
- op. mantenimiento ⇒ *desbalanceo* del árbol ⇒ pérdida de eficiencia en la búsqueda
  - → ***árboles 1-balanceados AVL*** ⇒ gestión bastante simple y eficiente
    {altura máx. 1,44 $\log_2(N+2)$ y ≈ 1 reorg. local cada 2 inserciones y cada 4 eliminaciones y 1 reorganización no implica más de 5 reasignaciones}
- no adecuado para tratamiento en bloques (ubicación no predecible del nodo en bloque)
  → *demasiados accesos a bloques* (hasta 1 por nodo)
  - → ***árboles binarios (AVL) paginados*** / ***árboles multicamino*** } ⇒ gestión eficiente (balanceo) bastante compleja

Estructuras de árbol: *árboles binarios paginados.*

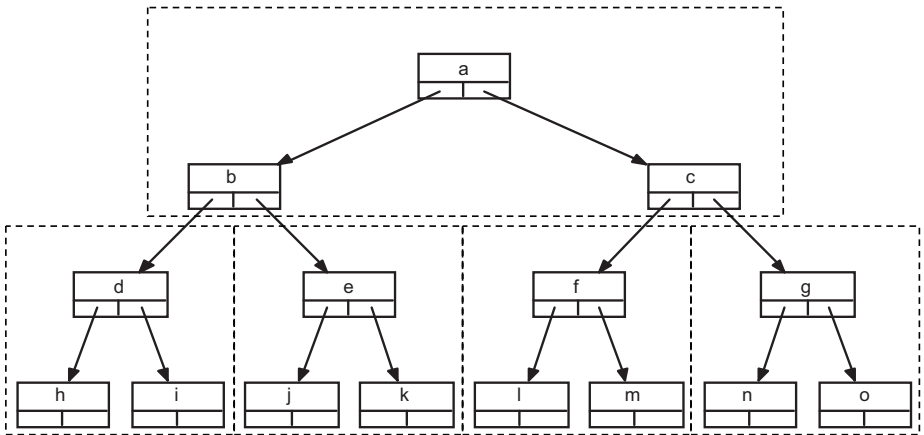

ejemplo de árbol binario paginado (3 nodos/bloque)

Concepto de árbol B: *definición* (original)

solución: ☛ ***árboles B*** *(≈ multicamino de orden variable y balanceados)*

árbol B *de orden* ***m*** *(Bayer y McCreigth 1972)* — ***m*** *≡ nº mínimo de item por nodo*

- los item (datos o claves) de cada nodo están ordenados por clave
- *la raíz* tiene entre **1** y **2m** item
- *el resto de los nodos* tiene entre **m** y **2m** item
- un nodo con ***k*** *item* tiene ***k+1*** *descendientes* (excepto las hojas)
  - *el* ***i-ésimo*** *subárbol tiene todos los item con clave comprendida entre las claves (i-1)-ésima e i-ésima del nodo considerado (si existen)*
- todos los nodos terminales (hojas) están al mismo nivel (completamente balanceado)

1 nodo por bloque ⇒ factor ocupación (f_C) > 50 % (≈70%)

Concepto de árbol B: *definición* (generalizada)

árbol B *de orden* ***m*** *(Knuth)* — ***m*** *≡ nº máximo de descendientes por nodo*

- los item (datos o claves) de cada nodo están ordenados por clave
- *la raíz* tiene entre **2** y **m** descendientes
- *el resto de los nodos* tiene entre **(m-1) div 2 + 1** y **m** descendientes (excepto las hojas) — **= (m + 1) div 2**
- un nodo con ***k*** *descendientes* tiene ***k-1*** *item* (excepto las hojas)
  - *el* ***i-ésimo*** *subárbol tiene todos los item con clave comprendida entre las claves (i-1)-ésima e i-ésima del nodo considerado (si existen)*
- todos los nodos terminales (hojas) están al mismo nivel (completamente balanceado)

1 nodo por bloque ⇒ factor ocupación (f_C) > 50 % (≈70%)

altura *(≈ nº de accesos)* $\approx 1 + \log_{\lceil p*m \rceil}((N+1)/2)$ siendo *p* el factor de ocupación (bloque)

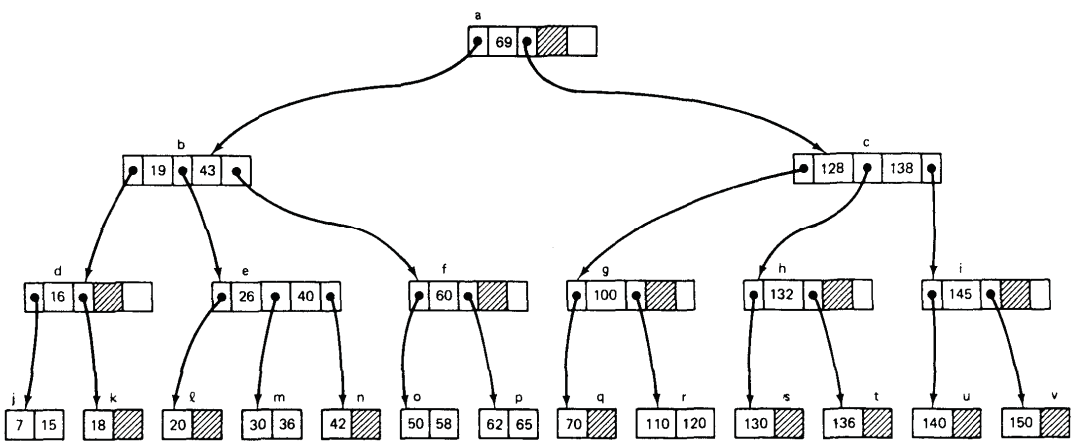

ejemplo de un ***árbol-B*** de órden 3

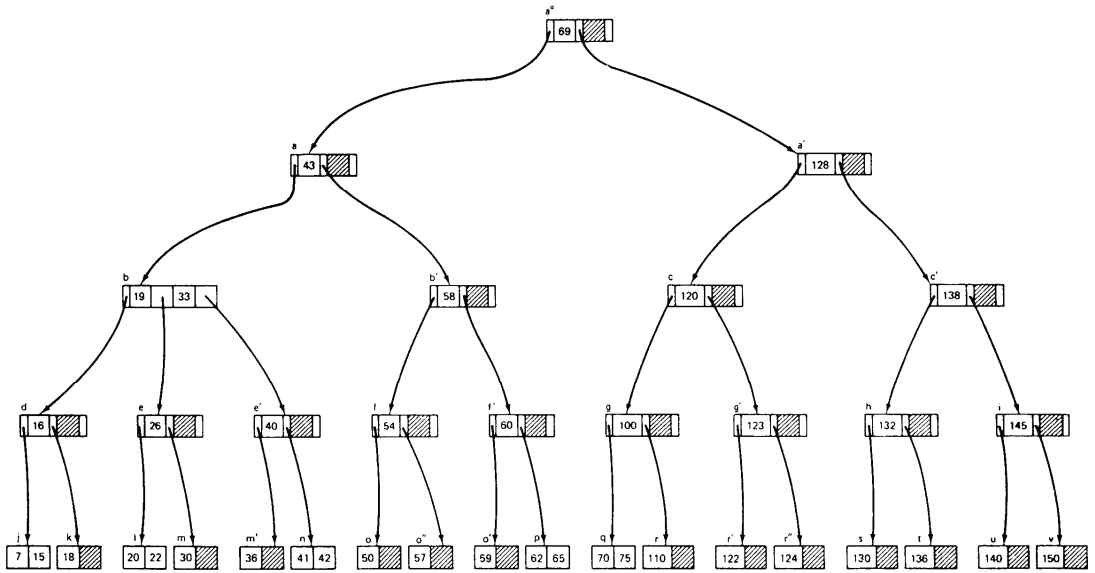

árbol-B tras la inserción de 22, 41, 59, 57, 54, 33, 75, 124, 122, 123 en el árbol de la figura anterior

ejemplo de inserción en un árbol B. (1)

implementación (ejemplo 1): **INSERCIÓN**

suponiendo un árbol B de orden 4 *(knuth), realizar las operaciones de* inserción de*:*
C, D, S, T, A, M, P, I, B, W, N, G, U, R, K, E, H, O, L, J, Y, Q, V, X, Z

- ***maxClavesNodo*** *= **3**;* ***minClavesNodo*** *= (4-1) div 2 = **1**;*
- ***nClavesNodoIzqDiv*** *= 4 div 2 =* ***2*** (claves en el nodo de la izquierda al dividir un nodo)

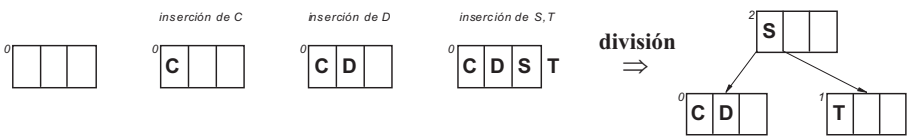

ejemplo de inserción en un árbol B. (2)

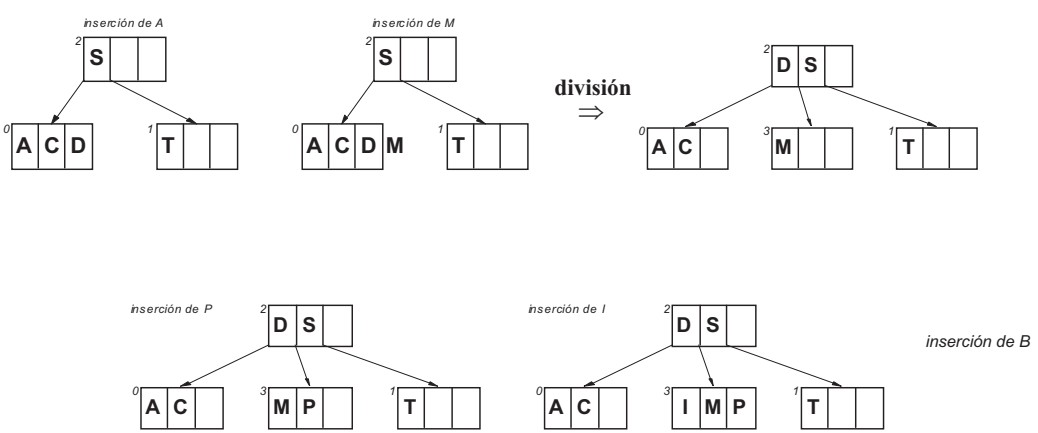

ejemplo de inserción en un árbol B. (3)

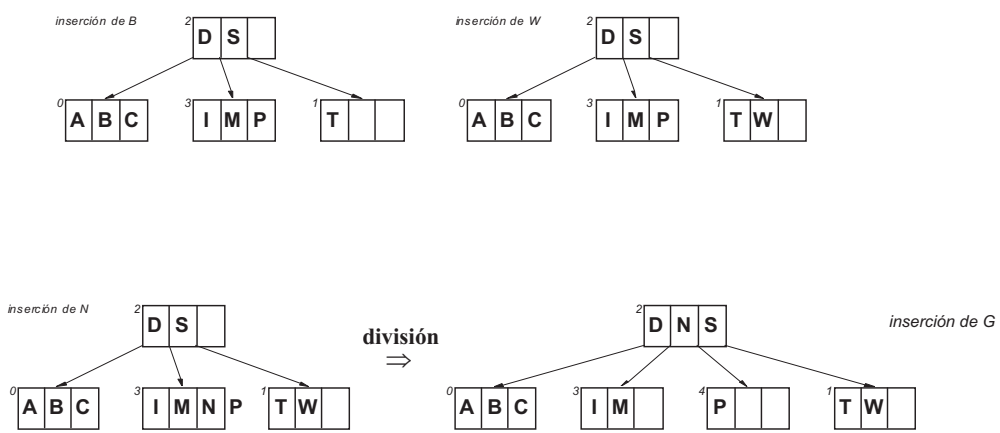

ejemplo de inserción en un árbol B. (4)

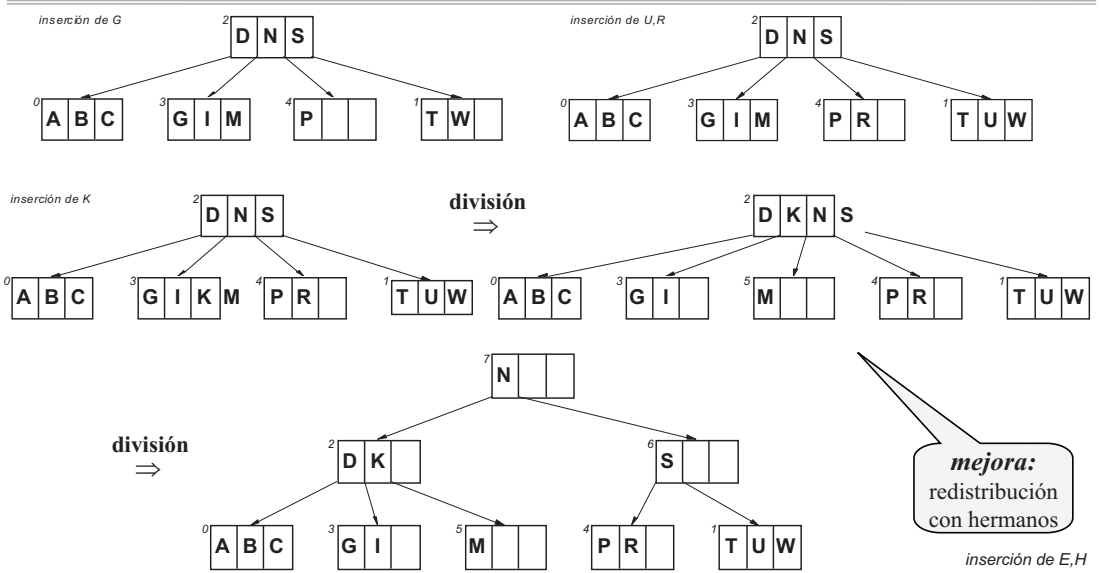

ejemplo de inserción en un árbol B. (5)

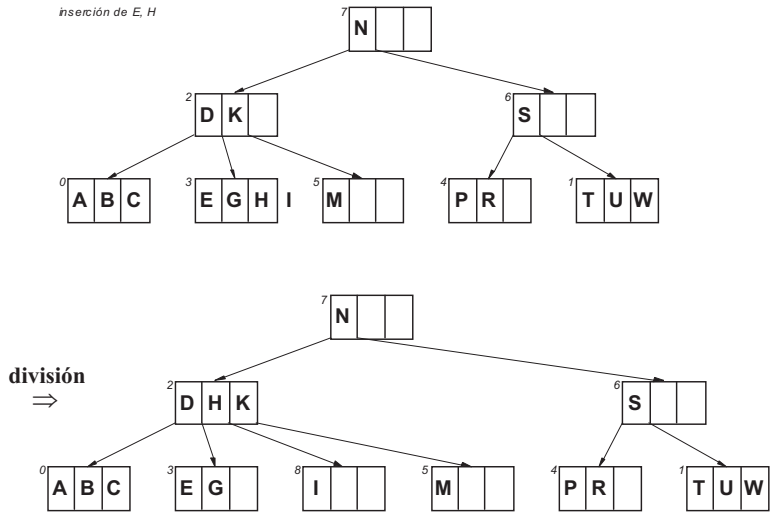

ejemplo de inserción en un árbol B. (6)

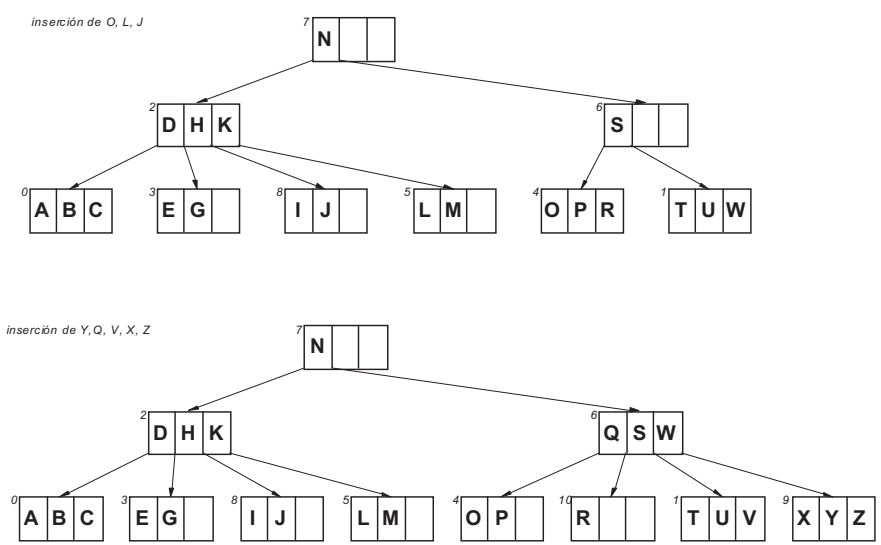

inserción en un árbol B : *algoritmo básico*

resumen de ideas: **pasos en la INSERCIÓN**

1) buscar el dato (clave) ⇒ descender hasta las hojas

Si *datoEncontrado* **entonces** *fin* {error, el dato ya existe} **Fsi**

☛ *siempre se comienza la inserción en las hojas*

2) insertar en nodo:

Si *nºdatosNodo* < ***(m-1)***

entonces *guardar_en_nodo* {colocar en posición correspondiente}

si no Si *hueco_en_hermano* **entonces** *redistribuir* {con nodo hermano} → afecta al nodo padre

si no {división del nodo}

crear_nuevo_nodo;

redistribuir_con_nuevo_nodo; → afecta al nodo padre

insertar_en_nodo_padre(nuevo_dato); {promoción dato "central"} → Si es la raíz ⇒ nueva raíz

Fsi

ejemplo de algoritmo de inserción en un árbol B. (1)

```
constantes
  ordenArbol = 6;                          {nº máximo de descendientes de un nodo}
  nMinClvNodo = (ordenArbol - 1) div 2;    {nº mínimo de claves en un nodo}
  nClvDivNodo = (ordenArbol) div 2;        {nº claves de la pag.(nodo) Izqda. al dividir un nodo}
  nMaxClvNodo = ordenArbol - 1;            {nº máximo de claves en un nodo}
tipos
  refNodo = ^tp_Nodo;                      { implementación en memoria, para simplificar }
  tp_Item = registro
              clave:   tp_Clave;
              valDato: tp_Dato;
              p:       refNodo
            fReg;
  tp_Nodo = registro
              contItems: 0..nMaxClvNodo;
              p0:        refNodo;
              item:      vector[1..nMaxClvNodo] de tp_Item
            fReg;
```


ejemplo de algoritmo de inserción en un árbol B. (2)

```
procedimiento insertarItem (ref. a: refNodo; valor u: tp_Item);
variables  q: refNodo;
           promocion: booleano;
principio
  promocion := false;
  ponEnArbol(a, u.clave, promocion, u);
  si promocion entonces {crear nueva raíz con item u}
      q := a;  nuevoDato(a);
      a^.contItems := 1;  a^.p0 := q;  a^.item[1] := u
  fsi;
fin;
```


ejemplo de algoritmo de inserción en un árbol B. (3)

```
procedimiento ponEnArbol(a: refNodo; laClave: tp_Clave;
                         ref. promocion: booleano; ref. v: tp_Item);
variables k: entero;  encontrado: booleano;   q: refNodo;
principio  {la clave no está en la página a^; promocion=falso}
  si a = nil
    entonces promocion := true {el item no está en el árbol }
    si no
      buscaEnNodo(a, laClave, k, encontrado);
      si encontrado
        entonces    promocion := falso
        si no {el item no está en la página}
          q := sucesor(item[k - 1]);
          ponEnArbol(q, laClave, promocion, v);
          si promocion entonces  insertar(a, k, v, promocion) fsi
      fsi
  fsi
fin; {ponEnArbol}
```


ejemplo de algoritmo de inserción en un árbol B. (4)

```
procedimiento insertar (a:refNodo; pos:entero;
                        ref. u:tp_Item; ref. promocion:booleano);
variables    b: refNodo;
principio
  si a^.contItems < nMaxClvNodo
    entonces { insertar u en la posición pos} promocion := false;
    si no  {la pagina a^ está llena ⇒ dividirla y promocionar item }
      nuevoDato(b);
      redistribuir_Items(a,b,u); {los de a^ y u en las páginas a^ y b^}
  fsi                            {devuelve en u el item a promocionar}
fin; {de insertar}
```

sólo aspectos básicos

ejemplo de eliminación en un árbol B. (1)

implementación (ejemplo 2): **ELIMINACIÓN**

suponiendo un árbol B de orden 6 *(knuth), realizar las operaciones de* eliminación de*:*
J, M, R, A

maxClavesNodo* = *5*; *minClavesNodo = *(6-1) div 2 =* ***2***;
nClavesNodoIzqDiv = *6 div 2 =* ***3*** (claves en el nodo de la izquierda al dividir un nodo)

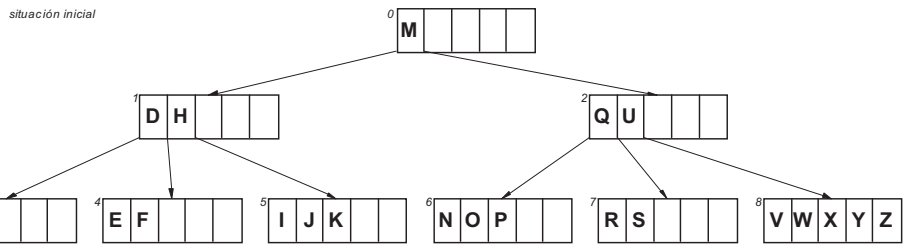

ejemplo de eliminación en un árbol B. (2)

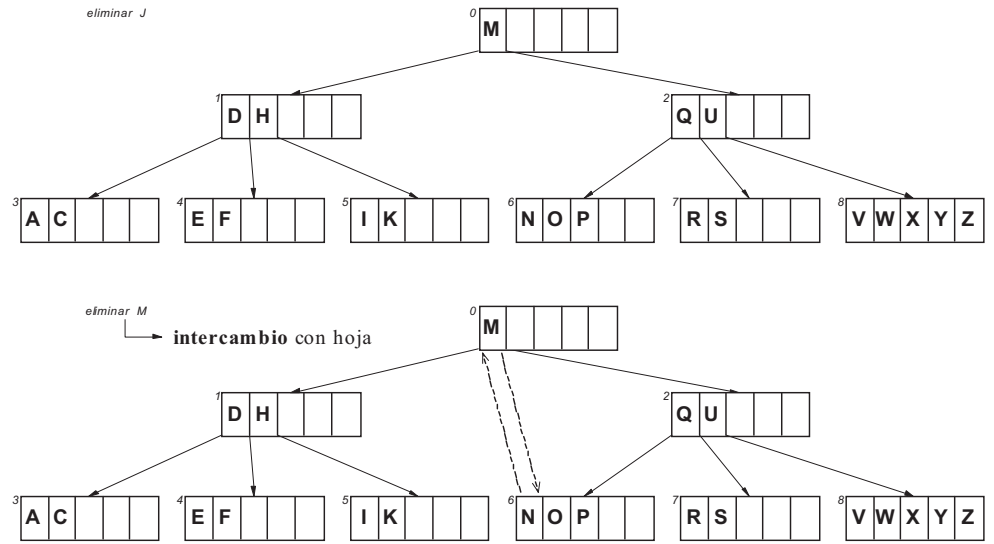

ejemplo de eliminación en un árbol B. (3)

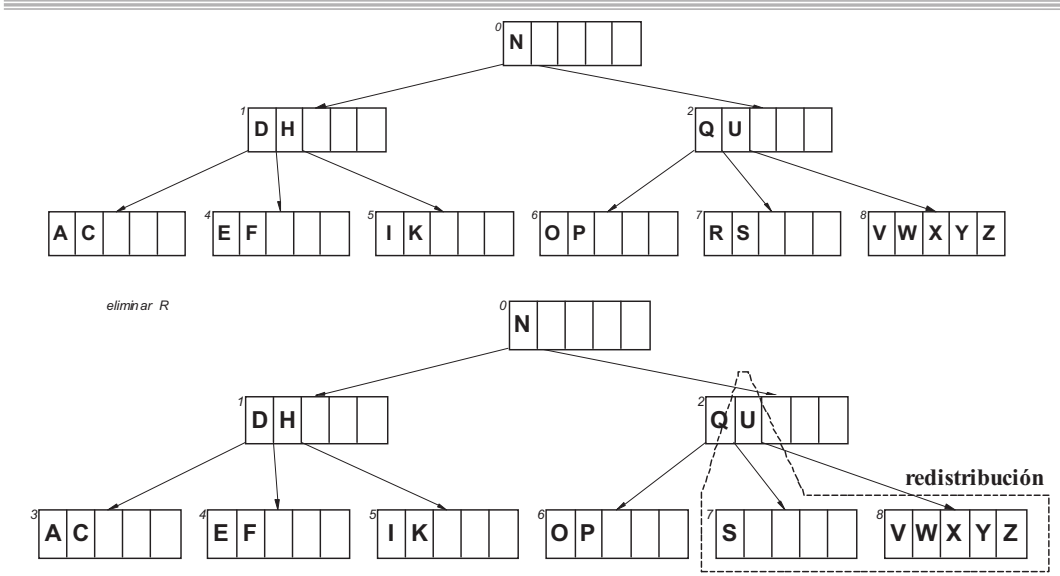

ejemplo de eliminación en un árbol B. (4)

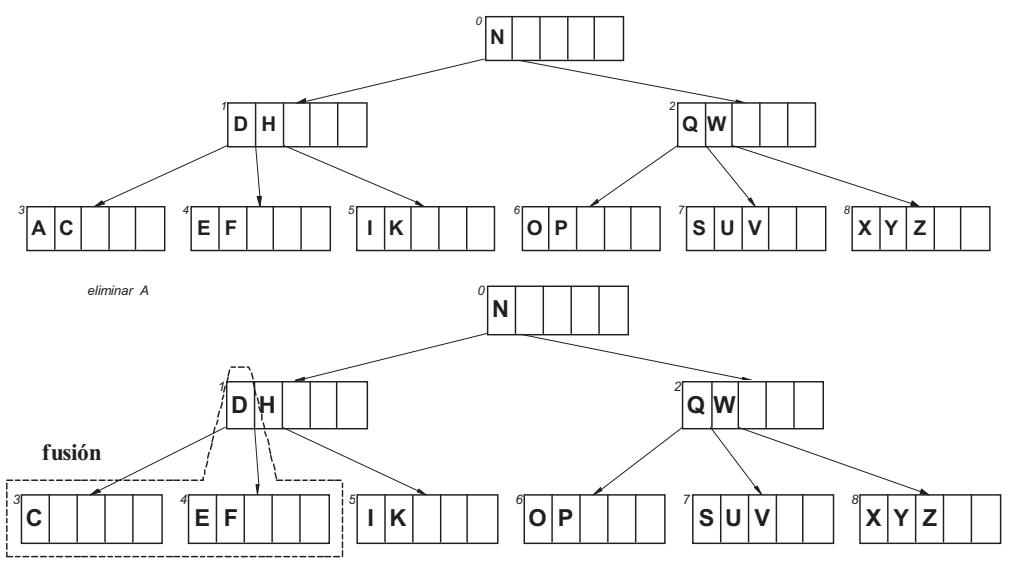

ejemplo de eliminación en un árbol B. (5)

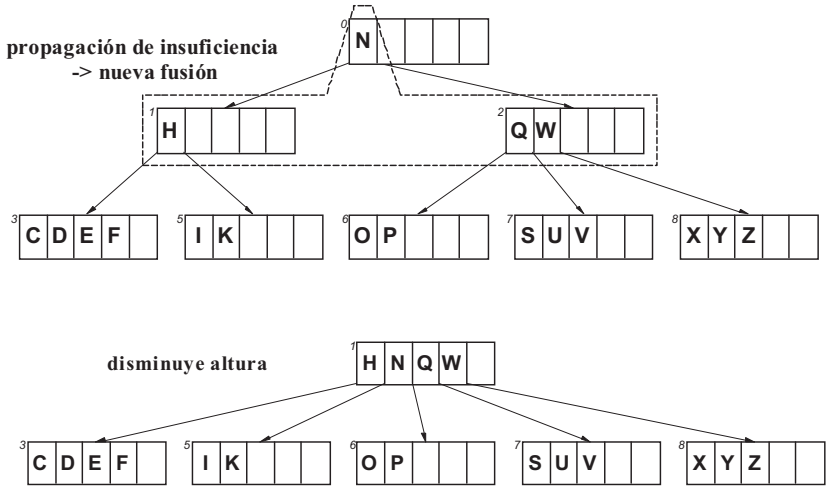

eliminación en un árbol B : *algoritmo básico*

resumen de ideas: **pasos en la ELIMINACIÓN**

1) buscar el dato (clave) → nodo en que está ubicado
   Si nodo = nil **entonces** *fin* {error, el dato no existe} **Fsi**

2) **Si** *nodo no-terminal* **entonces** *intercambiar_Con_Mayor_Hijo_Ant* **Fsi**
   (*ó Menor_Hijo_Post*)
   ☛ *siempre se comienza la eliminación en las hojas*

3) eliminar de nodo:
   Si *nºdatosNodo > (**m**-1) div 2*
   entonces *quitar_del_nodo* {recolocar el resto de los datos}
   si no Si *dato_en_hermano* **entonces** *redistribuir* {con nodo hermano}
   si no {fusión con nodo hermano}
   añadir_datos_hermano;
   eliminar_nodo_hermano;
   eliminar_de_nodo_padre(nuevo_dato); {promoción de "hueco"}
   Fsi

   (afecta al nodo padre)
   (Si es la raíz ⇒ disminuye un nivel)

ejemplo de algoritmo de eliminación en un árbol B. (1)

```
procedimiento eliminarItem (ref. a: refNodo; laClave: tp_Clave);
variables   q: refNodo;
            promocion: booleano;
principio
  promocion := falso;
  borrar(a, laClave, promocion);
  si promocion entonces {se ha eliminado dato de la raíz}
    si a^.contItems = 0 entonces {si no hay datos, disminuir nivel}
       q := a;  a := q^.p0;  disponer(q)
    fsi
  fsi
fin;
```


ejemplo de algoritmo de eliminación en un árbol B. (2)

```
procedimiento borrar (a: refNodo; clv: tp_Clave; ref. promocion: booleano);
variables  posClv: entero;  encontrado: booleano;
           rfHijoAnt: refNodo;
principio { de borrar }
  si a = nil entonces promocion := falso {la clave no está en el arbol}
    si no
      buscaEnNodo(a, clv, posClv, encontrado);
      rfHijoAnt := sucesor(item[posClv - 1]);
      si encontrado
        entonces  {encontrada, ahora se borra item[posClv] }
          si rfHijoAnt = nil entonces  { a es una página terminal }
              eliminar_Item;  promocion := a^.contItems < nMinClvNodo;
          si no
              ponMayorHijo(rfHijoAnt, a, posClv, promocion);
              si promocion entonces subocupacion(a, rfHijoAnt, posClv-1, promocion) fsi
          fsi
        si no {no encontrada, buscar en descendientes}
          borrar(clv, rfHijoAnt, promocion);
          si promocion entonces  subocupacion(a, rfHijoAnt, posClv-1, promocion) fsi
      fsi
  fsi
fin; {de borrar}
```

árbol B : *ejemplo de implementación.*

ejercicio: Transformar los algoritmos anteriores (E.D. en memoria) para implementar un árbol B representado sobre un fichero.

ideas:
- ✓ E.D. Soporte → fichero directo (con operadores nuevoDato (nodo) y eliminarDato, . . .)
- ✓ acceso a dato dinámico → cargar dato en memoria (leerDato(f, nodo, pos))
  + guardarlo si se ha modificado (o siempre para simplificar)

mejoras:
- ✓ guardar en memoria varios nodos ("pool" de páginas) con bit de modificación
  → *política de reemplazo . . .*
- ✓ eliminación de recursividad → referencias al padre y hermanos
  + pb.variables locales (bloque activación)

• • •

árbol B : *evaluación.*

evaluación:

- cada nodo tiene
  - **m** *ref. de bloque +* ***m-1*** *datos +* n^o *datos (1 byte)*
  - ò **m** *ref. de bloque +* ***m-1*** *claves +* ***m-1*** *ref. dato +* n^o *datos (1 byte)*
- n^o medio de accesos *(k descendientes por nodo):* $A \approx h - (1/(k-1))$

ejercicio: deducir las expresiones de la ocupación y número de accesos para un árbol B cuya raíz tiene ***z*** descendientes y el resto de los nodos ***k*** descendientes, y aplicarlo a un ejemplo concreto.

mejora de prestaciones ⇒ *reducir* n^o *de accesos a nodos*

mejora de las prestaciones del árbol B.

algunas ideas:

- mejorar redistribución en inserción y eliminación → *pasar a* $f_C \approx 85\%$
- cambiar las reglas de fusión y división → *árboles B**
- **separar índice de datos** ⇒ ↑*factor de bloque de los nodos*
- implementar índices no-densos ⇒ *tratamiento especial de las hojas*
  → **secuencial indexada** → sin ref. a nodos y ≠ orden
- árboles B de órden variable → *gestión más compleja (≈ árboles B+ de prefijos simples)*
- aprovechar la memoria central → *árboles B-virtuales (árboles B con buffer en memoria)*
  - política de gestión páginas →
    - mantener niveles altos (raíz + ..)
    - últimos niveles LRU
    - soluciones intermedias LRU ponderando el nivel

  • • •
- otros tipos de árboles

☛ ***reestructuración*** periódica (copiar) ⇒
- ↑*factor de ocupación*
- ↑*ordenación de nodos (mejora acceso)*

concepto de árbol B*.

objetivo: mantener un alto factor de ocupación (f_C) de los nodos

idea básica:
- retrasar la división de un nodo hasta tener 2 llenos → *redistribución*
- en la división, repartir los items de los 2 nodos entre 3 (los 2 + el nuevo)
  → *mínimo* (f_C) $\approx 70\%$

problema: la división del nodo raíz (no tiene hermanos)
- tratamiento especial como árbol B
- permitir que pueda ser más grande (hasta 4/3) → *pb. repres.*

árbol B* *(Knuth) de orden* ***m*** *(*n^o *máximo descendientes)*

≈ árbol B, excepto que:
- *los nodos* tienen entre 2***(m-1) div 3 + 1** y **m** descendientes (excepto la raíz y las hojas)
- *la raíz tiene tratamiento especial*

otras organizaciones indexadas basadas en árboles.

otros tipos de árboles:

tries ≡ árbol **m**-ario (el orden ***m*** es la base empleada para representar la clave)
cada camino desde la raíz a las hojas representa una clave

- cada nodo interior consta de ***m*** ref. de nodo
- cada hoja consta de ***m*** ref. a datos (índice denso)

problemas:
- claves de muy diferente longitud → ✓ *limitar altura del árbol* ✓ *representar nodo como lista*
- acomodación a los bloques

H-tree ≡ *(dispersión + árbol B)*

• • •

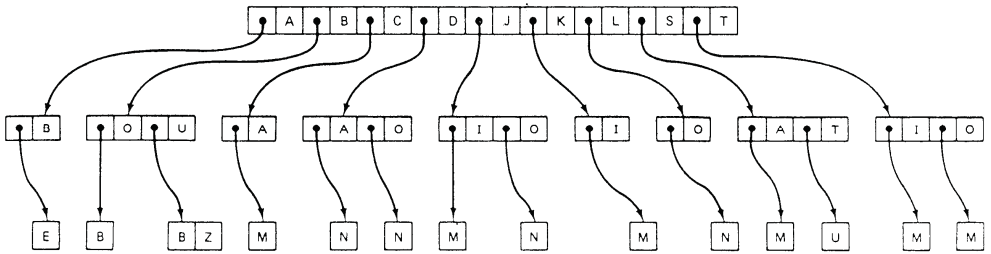

ejemplo de un ***trie*** para una colección de nombres de tres letras (en inglés) de niños

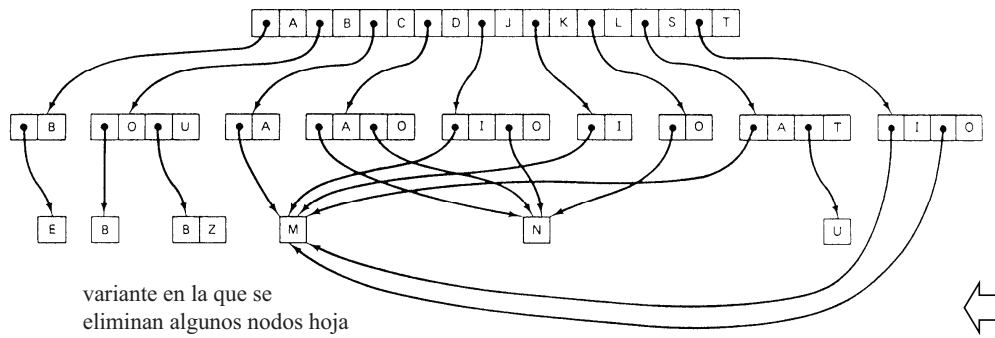

variante en la que se
eliminan algunos nodos hoja

3.5 - Familia de árboles B+ y organización secuencial indexada

objetivo: aprovechar las ventajas de las organizaciones
- indexada → *búsqueda*
- secuencial → *trat. secuencial*

idea básica: árbol (≈ árbol B) sobre una secuencia (conjunto de secuencias)

árbol B+
- toda la información (claves ò datos) está en un conjunto encadenado de bloques (hojas) ≡ ***conjunto secuencia***
- el árbol de acceso (≈ árbol B) está formado con copia de las claves (pueden estar repetidas), que actúan como separadores ≡ ***conjunto índice***

- tratamiento un poco diferente del árbol B (especialmente para las hojas)
- la altura es algo menor que para el árbol B

☛ *organización secuencial indexada* ≡ organización basada en un *árbol B+*

Organización
secuencial-indexada
de un fichero

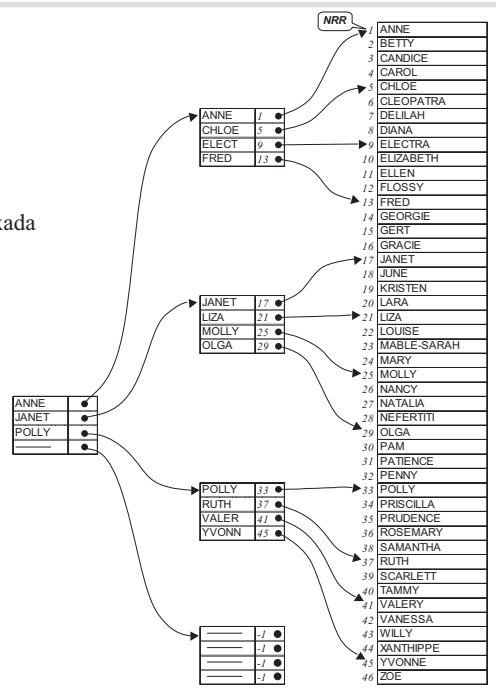

Fichero secuencial-indexado estructurado como un árbol B+

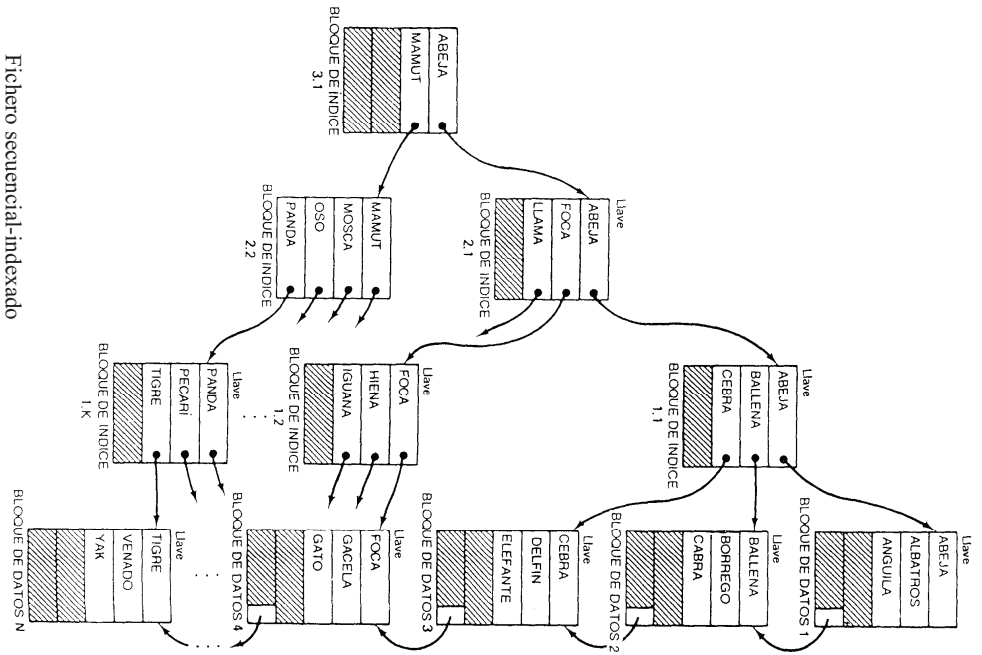

Organización secuencial-indexada de un fichero, con zona de desbordamiento

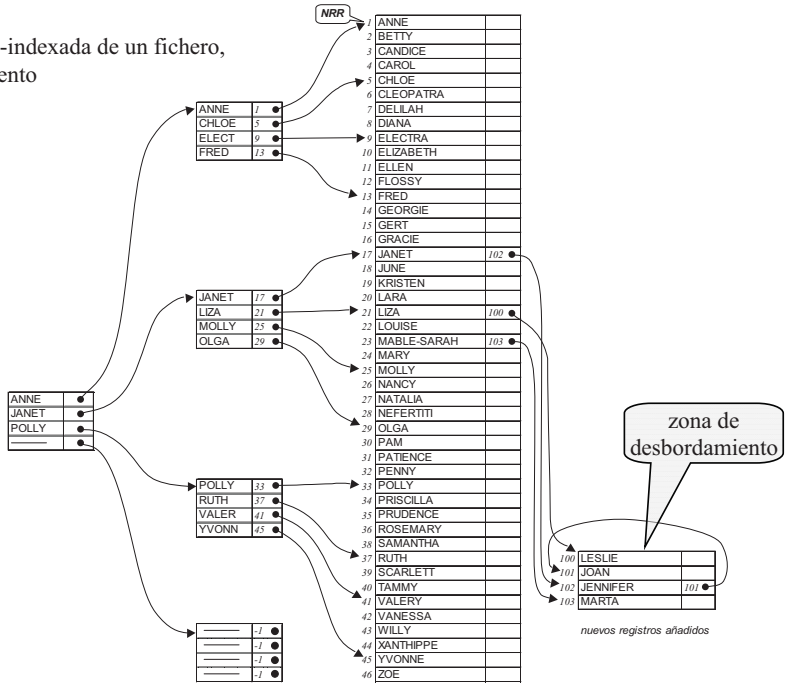

ejemplo de inserción en un árbol B+ (1)

implementación (ejemplo 1): **INSERCIÓN**

suponiendo un árbol B+ de orden 3 *(knuth)* para los nodos interiores, y de orden 4 para las hojas*, realizar las operaciones de* inserción de*:* **R, U, A, N, S, E, L, T, V**

- ***maxClvNodoInt*** = ***2***; ***minClvNodoInt*** = *(3-1) div 2 =* ***1***;
- ***nClvNodoIntIzqDiv*** = *3 div 2 =* ***1*** (claves en el nodo de la izquierda al dividir un nodo)
- ***maxClvNodoHoj*** = ***3***; ***minClvNodoHoj*** = *(3+1) div 2 =* ***2***;
- ***nClvNodoHojIzqDiv*** = *(3+2) div 2 =* ***2*** (claves en el nodo de la izquierda al dividir un nodo)

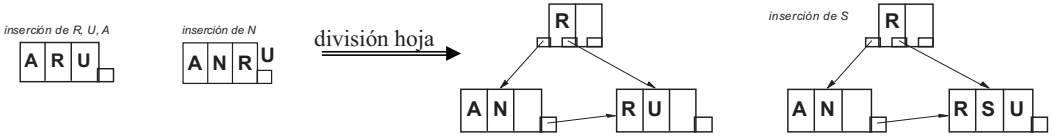

ejemplo de inserción en un árbol B+ (2)

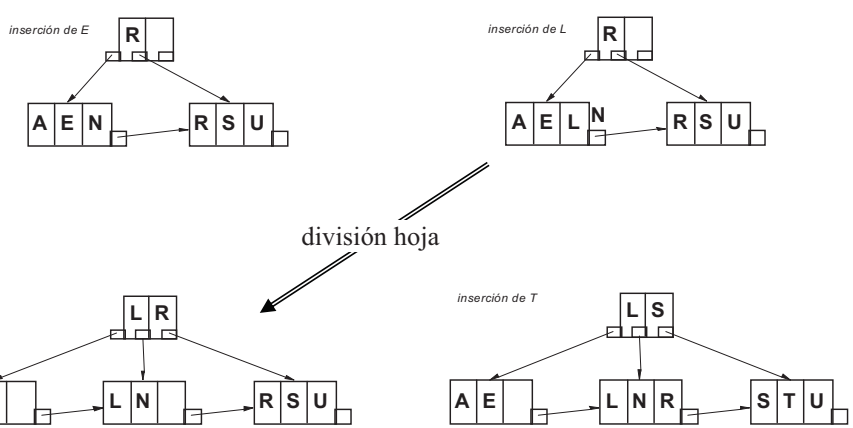

ejemplo de inserción en un árbol B+ (3)

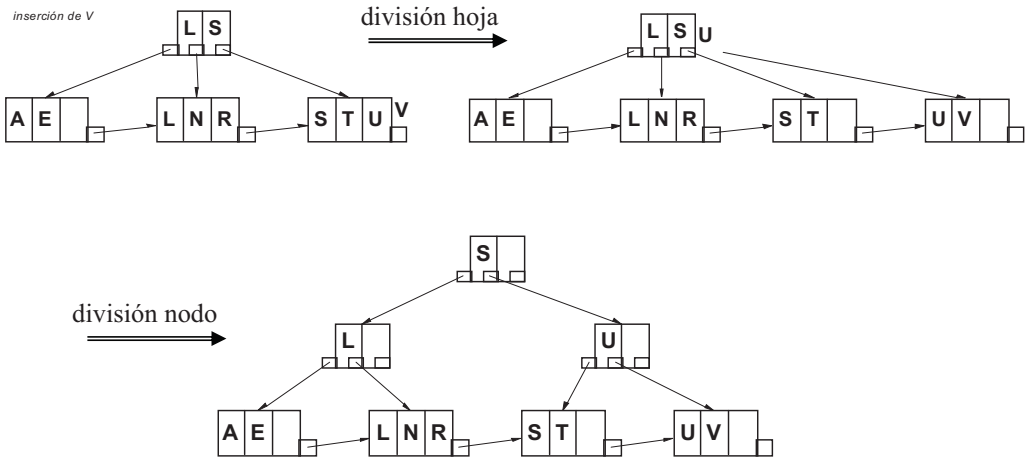

ejemplo de eliminación en un árbol B+ (1)

implementación (ejemplo 2): **ELIMINACIÓN**

suponiendo un árbol B+ de orden 3 *(knuth)* para los nodos interiores, y de orden 4 para las hojas*, realizar las operaciones de* eliminación de*:* **E, S, G**

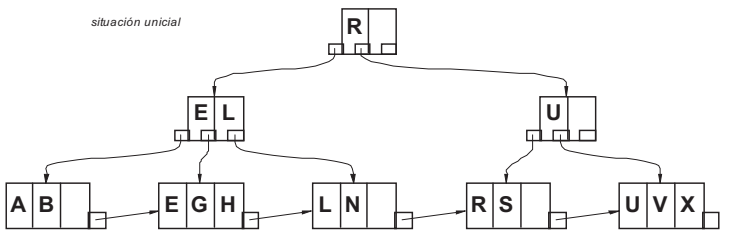

ejemplo de eliminación en un árbol B+ (2)

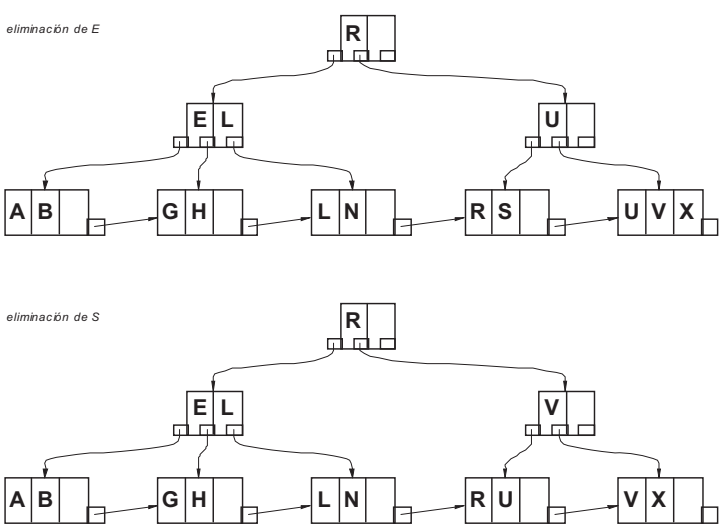

ejemplo de eliminación en un árbol B+ (3)

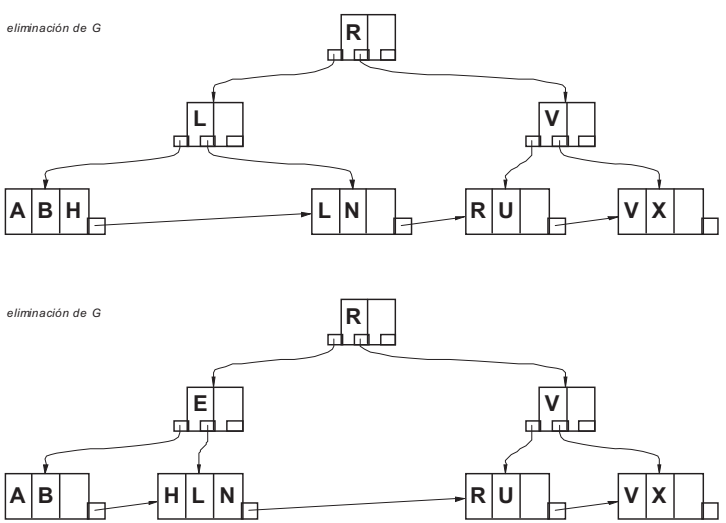

árbol B+ : *evaluación.*

evaluación:

- cada nodo hoja : ***m-1*** *datos* + ***1*** *ref. de bloque(hermano)* + *nº datos y tipo (2 bytes)*
- cada nodo interior : ***m-1*** *claves* + ***m*** *ref. de bloque(hijos)* + *nº datos y tipo (2 bytes)*
  ↘ tipo: nodo hoja o interior
- nº accesos : = *altura árbol* ≈ *árbol B*

ejercicio: deducir las expresiones de la ocupación y número de accesos para un árbol B+ cuya raíz tiene ***z*** descendientes y el resto de los nodos ***k*** descendientes, y aplicarlo al mismo ejemplo que el desarrollado para el árbol B.
Comparar los resultados obtenidos.

→ *Similar al árbol B. Se parte del cálculo de las hojas.*

árbol B+ : *evaluación.*

☛ *Implementación de* ***operadores de recorrido*** *(primero, siguiente)* ***más eficiente que en árbol-B***

☛ *en general es mejor el índice separado (fichero datos + fichero índice)*

- mayor eficiencia en organización secuencial (incluso contigua)
- mayor seguridad (recuperabilidad frente a errores)
- reconstrucción simple y eficiente del índice a partir del fichero de datos

→ *pb.: las referencias del último nivel son a otro fichero*

☛ ***reestructuración periódica para mantener (o mejorar) prestaciones***

- fichero índice
- fichero datos

☛ ***implementación de índices secundarios simple***

árboles B+ de prefijos simples

mejora de prestaciones ⇒ *reducir nº de accesos a nodos*

⇩

representar parte de la clave (prefijo) ⇒ aumenta el factor de bloque

☛ *árboles B+ de prefijos simples* ≡ orden variable (gestión un poco + compleja)

→ implementación de operaciones similar

Implementación de índices con claves repetidas (secundarios, agrupamiento, etc.): relativamente simple

→ diferentes soluciones (compromiso prestaciones-coste)

árboles B+ de prefijos simples: *ejemplo (1)*

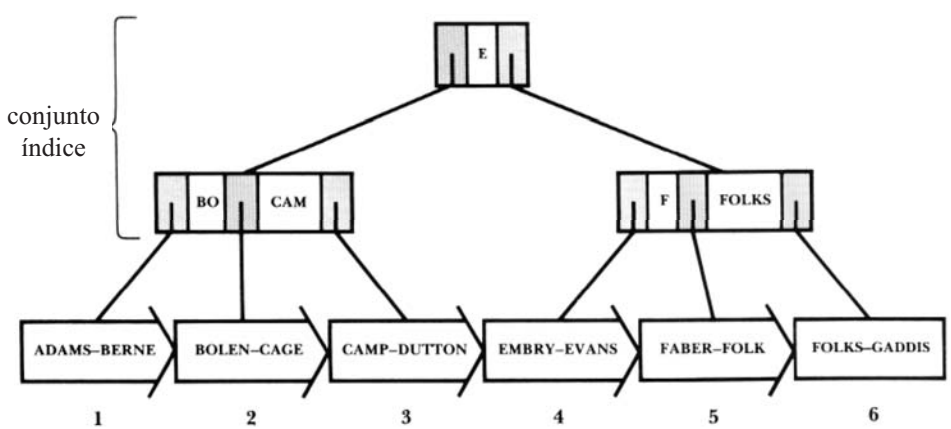

Un conjunto índice en forma de árbol B para el conjunto de secuencias, que forma un ***árbol B+ de prefijos simples***

árboles B+ de prefijos simples : *ejemplo* (2)

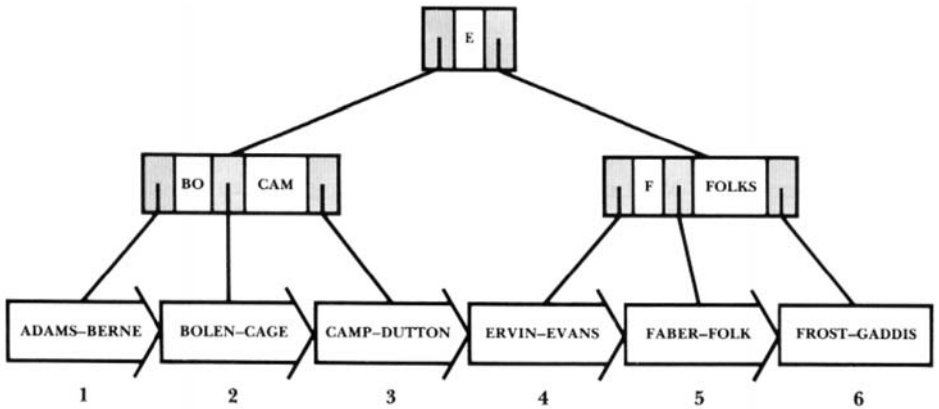

La eliminación de los registros EMBRY y FOLKS del conjunto de secuencias **no altera el conjunto índice**

árboles B+ de prefijos simples : *ejemplo* (3)

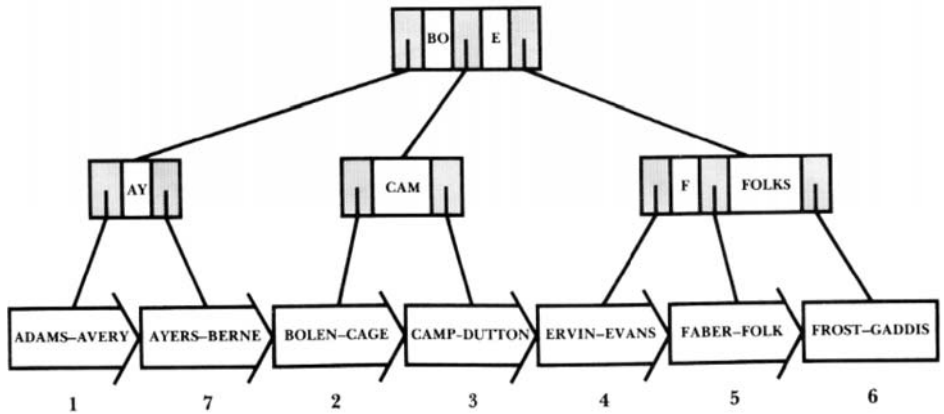

Una inserción dentro del bloque 1 provoca una división y la consecuente adición del bloque 7. La adición de un bloque en el conjunto de secuencias requiere un nuevo separador en el conjunto índice (AY). Este separador provoca la división del nodo y la promoción de BO a la raíz.

árboles B+ de prefijos simples : *ejemplo* (4)

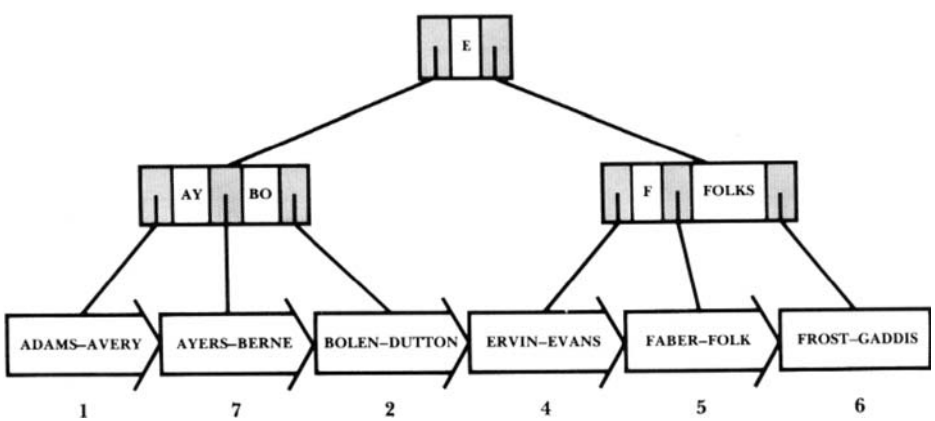

Una eliminación en el bloque 2 provoca insuficiencia y la consecuente concatenación de los bloques 2 y 3 (el bloque 3 se puede colocar en la lista de disponibles). Esta eliminación de un bloque conlleva eliminar el separador correspondiente (CAM), lo que provoca una insuficiencia y la consecuente reorganización del conjunto índice.

árboles B+ de prefijos simples : *implementación*

ejemplo de implementación de un nodo: